Plateforme Web de Machine Learning

Membres du groupe :

- Abderrahim Aamirrou & Imane Chalati & Halima Driouch

Encadrant du projet :

- Professeur Mohammed AMEKSA

Filière , Semestre et Année universitaire :

- IASD - 5e semestre - 2025 – 2026

1. Sujet du projet :

- Le projet consiste à concevoir une plateforme web interactive qui permet aux utilisateurs de charger différents types de datasets, comme ceux utilisés dans nos cas pratiques (*fitness_dataset.csv*, *calories_pred.csv*), et de réaliser des analyses, entraîner des modèles et effectuer des prédictions intelligentes sans avoir besoin de coder.

- **Dataset de Régression** — Calcul des Calories : Ce dataset contient des données numériques qui permettent de **prédire le nombre total de calories consommées** par une personne.

- **Dataset de Classification** — Fit ou Non Fit : Ce dataset contient des informations sur les calories consommées + d'autres paramètres et attribue à chaque personne une étiquette : **Fit** ou **Non Fit**.

2. Description de la Plateforme FitAI :

FitAI est une plateforme interactive développée par notre groupe dans le cadre de l'étude de l'apprentissage supervisé.
Elle a été conçue pour rendre l'entraînement, l'analyse et la comparaison des modèles de Machine Learning accessibles, simples et intuitifs.

L'objectif principal de **FitAI** est de permettre aux utilisateurs d'explorer les deux branches majeures de l'apprentissage supervisé :

- la régression,
- la classification.

Grâce à une interface claire et organisée, **FitAI** offre une expérience complète allant du traitement des données à l'interprétation des résultats.

FitAI permet à l'utilisateur d'insérer ses propres données, de choisir l'un des modèles disponibles, puis la plateforme calcule automatiquement les calories et prédit si la personne est Fit ou Non Fit selon les informations fournies.

3. Outils et Technologies Utilisés dans FitAI

Selon les recommandations de notre professeur, pour le développement de la plateforme **FitAI**, notre groupe a sélectionné des outils et technologies modernes afin de créer une application **fiable, interactive et pédagogique**. Ces choix ont permis de combiner **la puissance des modèles de Machine Learning** avec une **expérience utilisateur claire et intuitive**, facilitant à la fois l'expérimentation et l'apprentissage.

- **Algorithmes de Machine Learning** : Regression Linéaire, SVR, Arbre de Décision, Random Forest, XGBoost, Regression Logistique et SVM, pour effectuer des prédictions précises et classer les utilisateurs en Fit / Non Fit.
- **Fichiers .pkl** : Modèles entraînés enregistrés pour être réutilisés rapidement sans réentraînement.
- **Django** : Framework Python utilisé pour le back-end, la gestion des modèles et l'authentification des utilisateurs.
- **Front-End (HTML, CSS , Django Templates)** : Interface interactive et intuitive permettant à l'utilisateur d'insérer ses données, choisir un modèle et visualiser les résultats.
- **Datasets CSV** : Données d'entraînement et de test utilisées par les modèles, téléchargeables pour analyse complémentaire.

4. Architecture de la Plateforme :

a. Structure hiérarchique

Le dossier principal : Conteneur principal organisant les trois grands domaines du projet.

- **atelier** : Code de production
- **datasets** : Gestion des données
- **modeles avec code source ipynb** : Recherche et développement

b. Application Django : « atelier »

Le dossier **atelier** constitue la partie principale du projet.
Il contient **l'environnement complet de développement**, ainsi que tous les fichiers nécessaires au fonctionnement de la plateforme de Machine Learning.

Il contient :

- Le fichier requirements.txt : Ce fichier regroupe toutes les bibliothèques Python utilisées dans le projet (Django, NumPy, scikit-learn, XGBoost…). Il permet d'installer rapidement les dépendances nécessaires sur un autre ordinateur.
- Le dossier mlPlatform : contient :
    - Les modèles pré-entraînés de Machine Learning (fichiers .pkl)
    - Les scripts Python qui gèrent la logique du site
    - Les fichiers HTML et CSS pour l'interface
    - La base de données SQLite (**db.sqlite3**)
    - Les templates, images, pdfs du support
    - Le fichier principal **manage.py** pour exécuter le serveur.

- Le dossier migrations : est un dossier généré automatiquement par Django. Il joue un rôle essentiel dans la gestion de la base de données. Et pour des fichiers Python créés automatiquement par Django chaque fois que vous modifiez votre modèle (models.py).Ils servent à **traduire les changements du code vers la base de données SQLite**.
    - **0001_initial.py** : première création des tables
    - **0002_auto_XXXX.py** : modifications automatiques après changement dans les modèles
    - **__init__.py** : permet à Django de reconnaître le dossier comme un module Python

- Le dossier algoML : regroupe toute la logique liée aux algorithmes de Machine Learning, ainsi que la structure Django qui permet de les utiliser dans le site web. Et il est responsable sur **Les fichiers principaux du module Django** qui gèrent le comportement de la plateforme (Backend Django) :

    - **views.py** : Contient le code qui reçoit les données de l'utilisateur, exécute les modèles ML et renvoie les résultats vers l'interface.
    - **urls.py** : Définit toutes les routes de navigation vers les pages de classification, régression, détails des modèles…
    - **models.py** : Gère la structure de la base de données (par exemple l'historique des prédictions).

- **admin.py** : Permet de gérer les données depuis l'interface d'administration de Django.
- **apps.py** : Fichier standard du fonctionnement d'une application Django.

c. Machine Learning « ML Models »

- **Les modèles sont chargés depuis la plateforme via les fichiers .pkl.**

Classification	Régression
SVC	SVR
RandomForestClassifier	RandomForestRegressor
LogisticRegression	LinearRegression
XGBClassifier	XGBRegressor
DecisionTreeClassifier	DecisionTreeRegressor

5. GUIDE POUR DE NOTRE PLATEFORME PAR DES SCREENSHOTS SUIVIS PAR DES DESCRIPTIONS:

a. PAGE D'ACCUEIL :

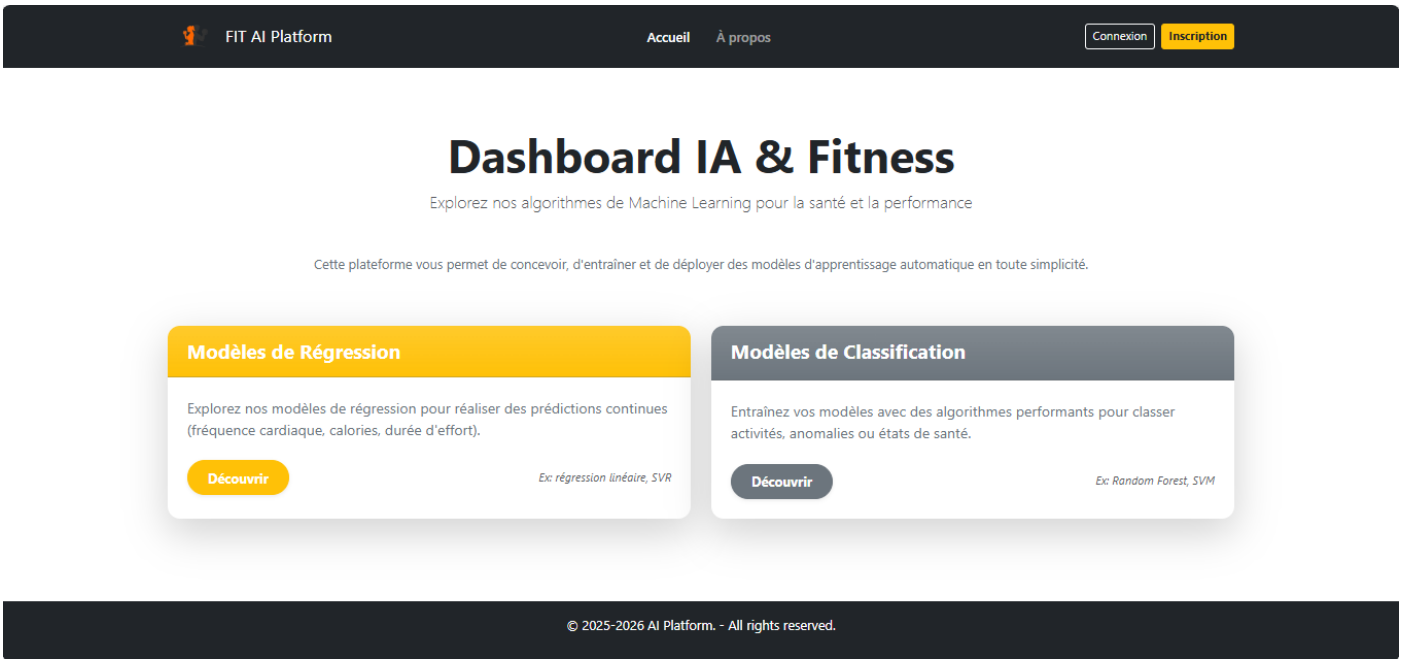

"Interface d'accueil intuitive présentant les deux types principaux de problèmes ML disponibles : Classification et Régression. Navigation simple vers les différentes fonctionnalités."

b. PAGE DE CONNEXION :

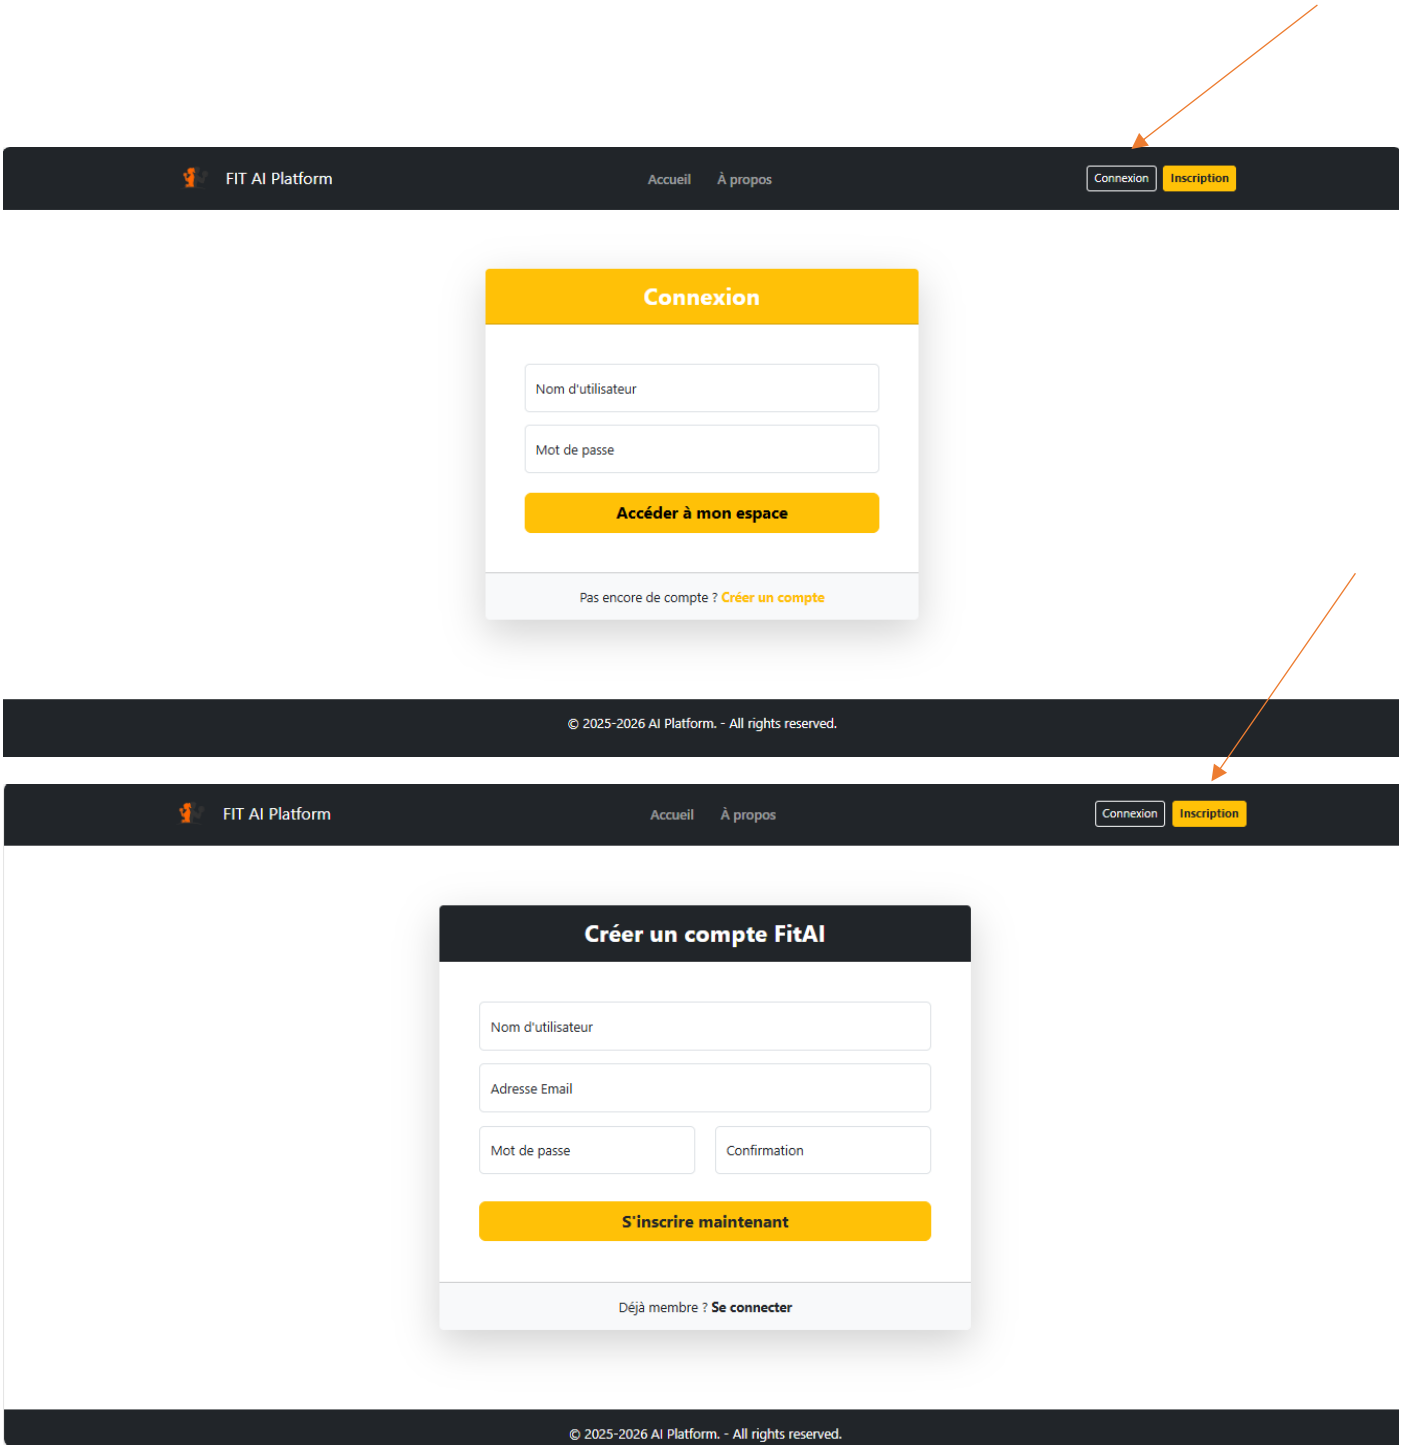

"Interface d'inscription simplifiée pour créer un compte utilisateur avec validation en temps réel."

c. INTERFACE ALGORITHMIQUE :

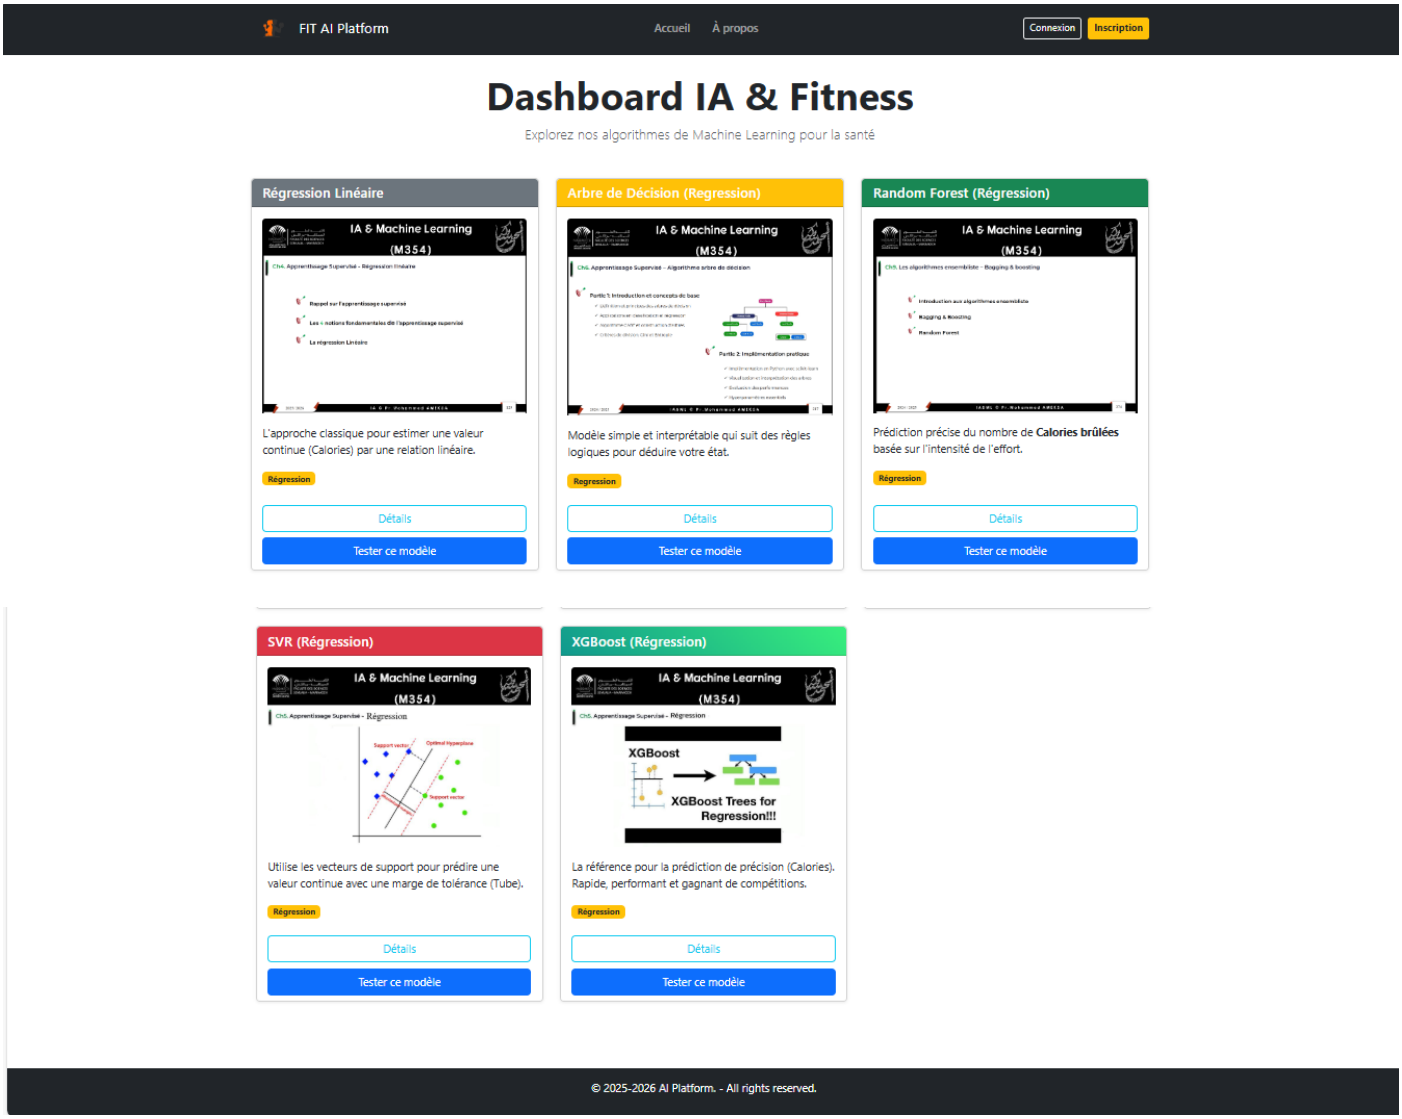

"L'interface affiche une galerie de 5 cartes algorithmiques disposées . Chaque carte représente un modèle de régression disponible. "

Et de même pour la classification :

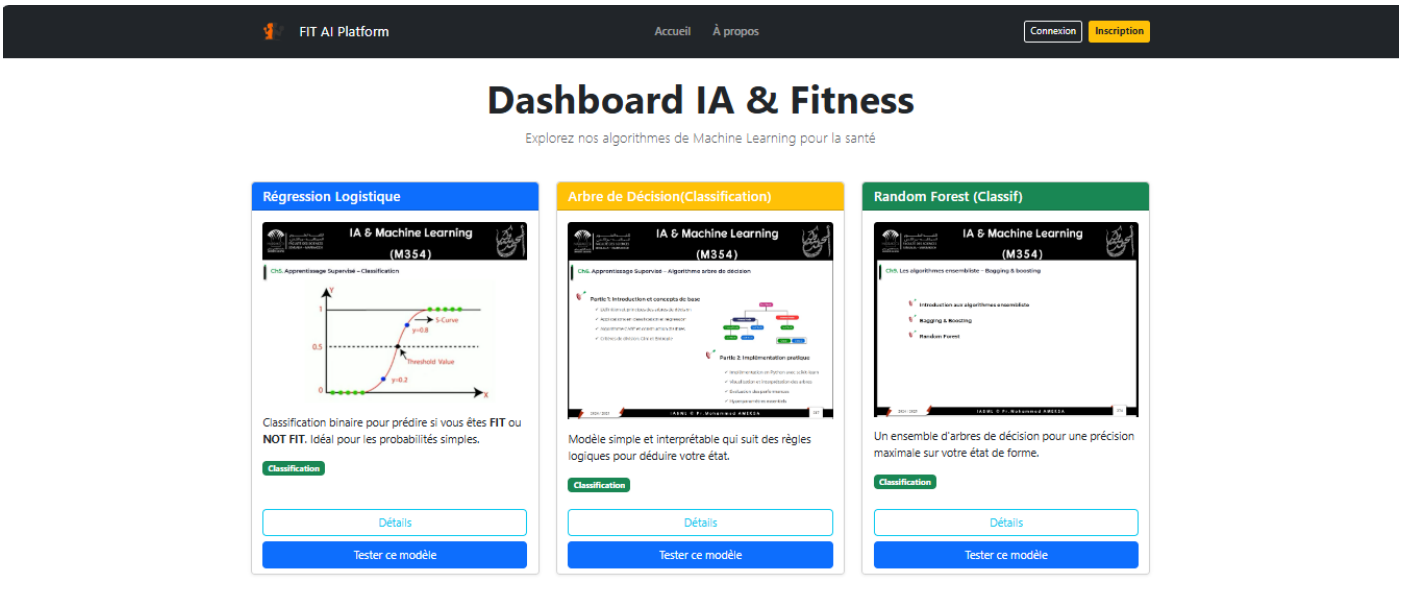

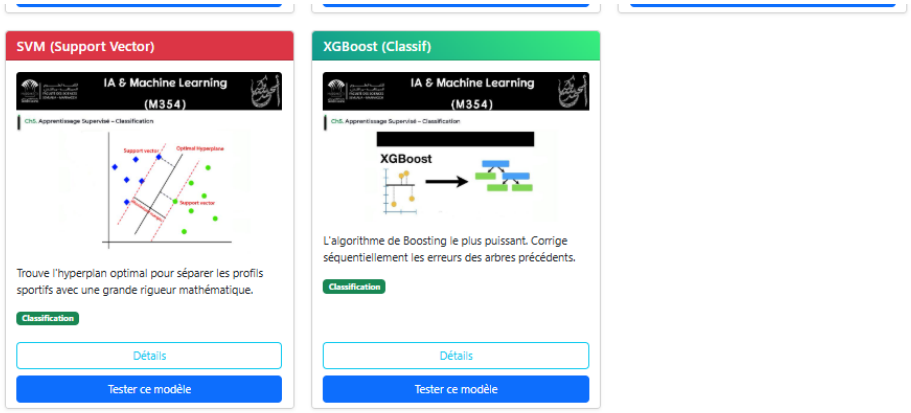

d. PAGE "À PROPOS" :

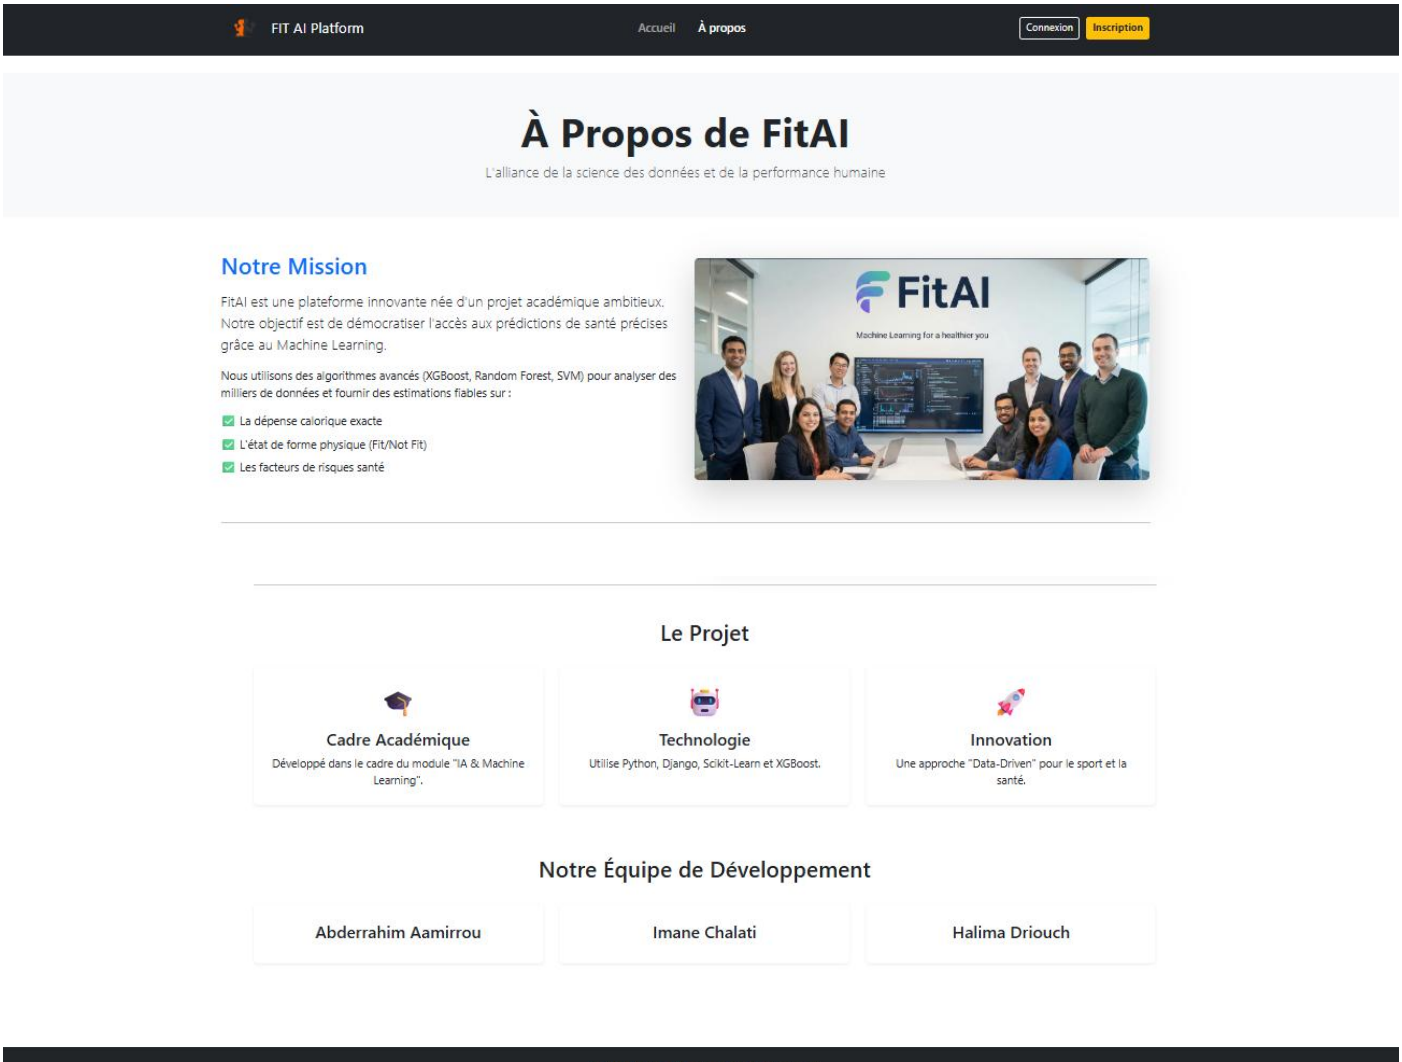

"Page informative présentant la plateforme ML, l'équipe de développement, et les technologies utilisées, avec design professionnel et sections organisées. "

e. Détails des algorithmes :

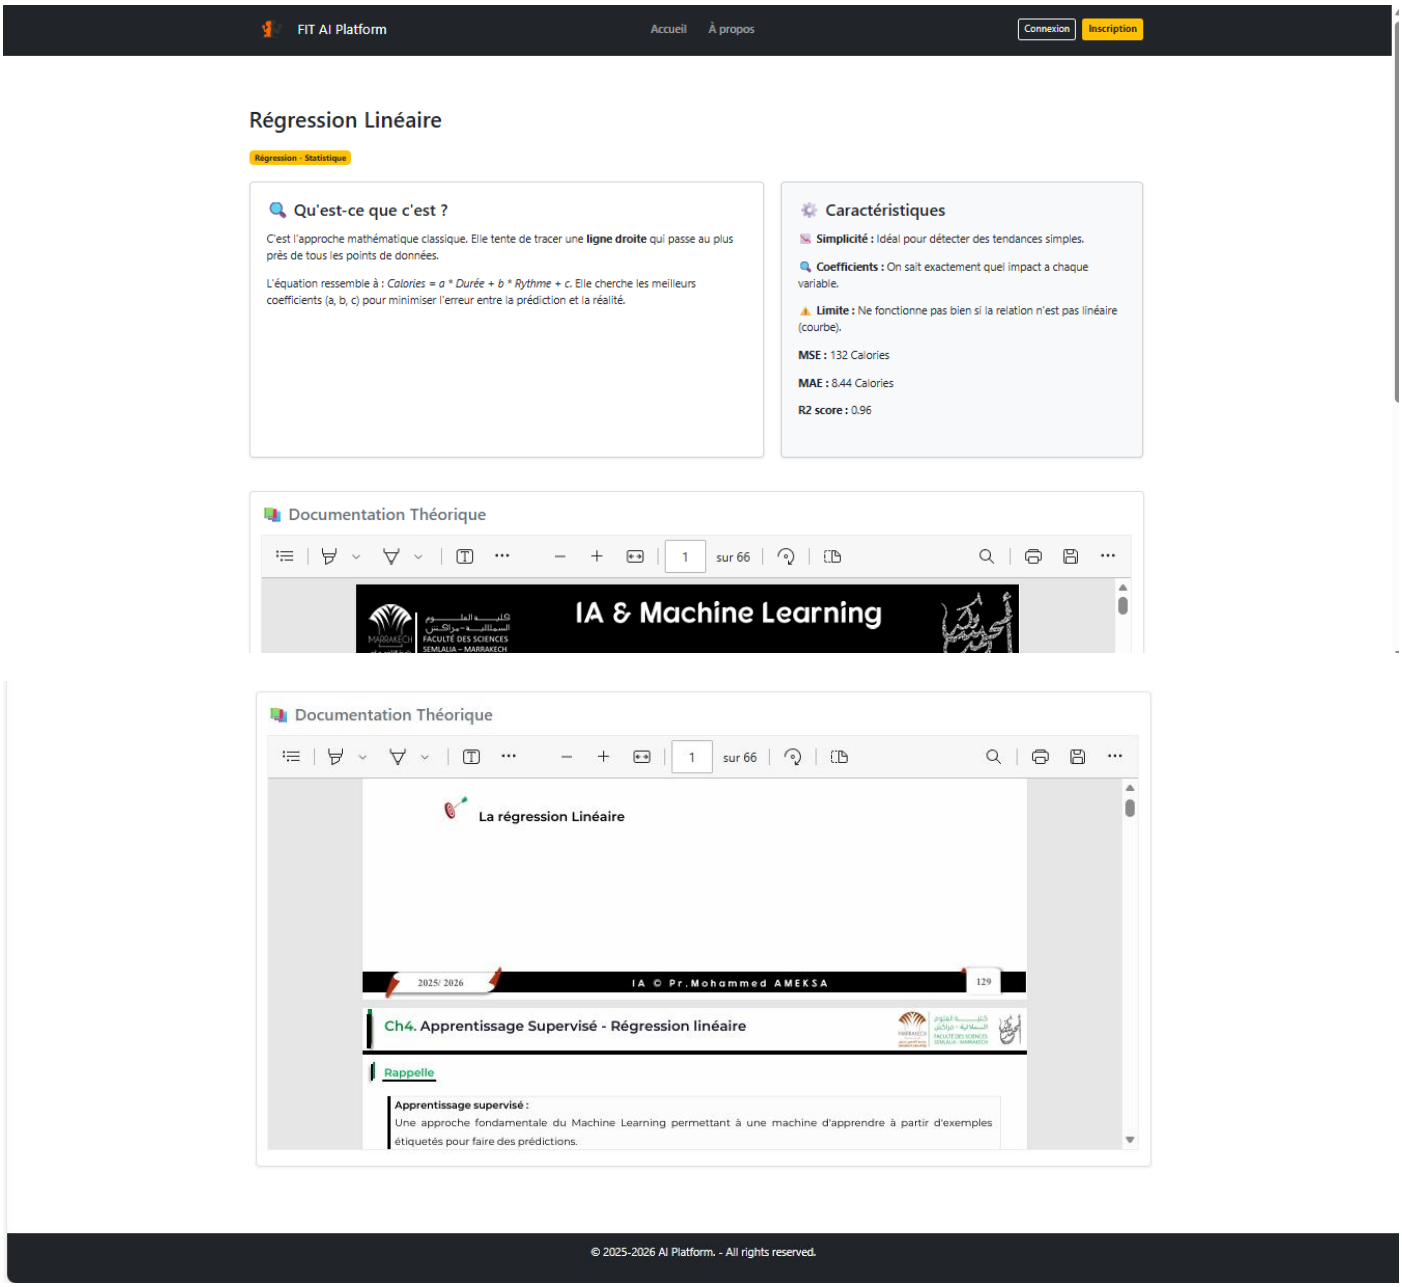

" Pages spécialisées pour chaque algorithme avec explications théoriques et des pdfs de cours et pour les chapitres restant nous avons choisis des cours sur le web ."

f. TESTEUR DE MODÈLES :

Pour Régression (prédiction des calories):

Avant la prédiction :

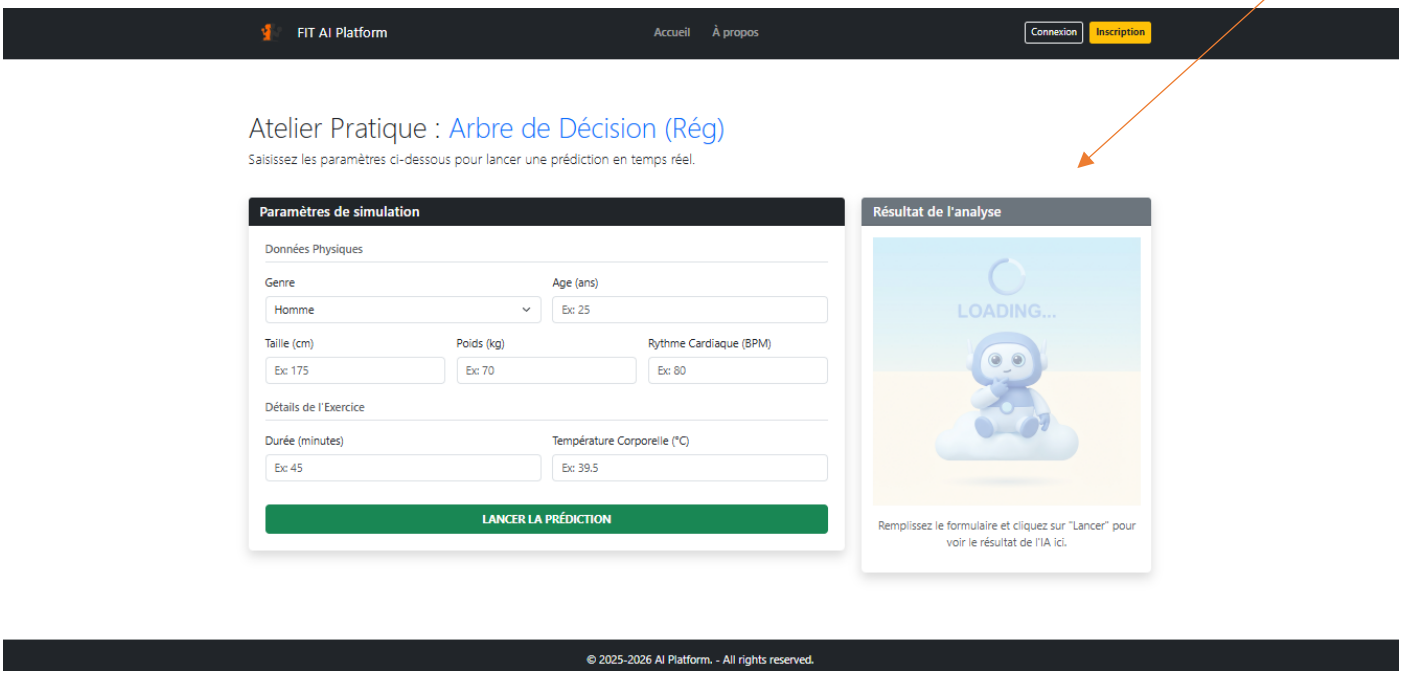

Après le test :

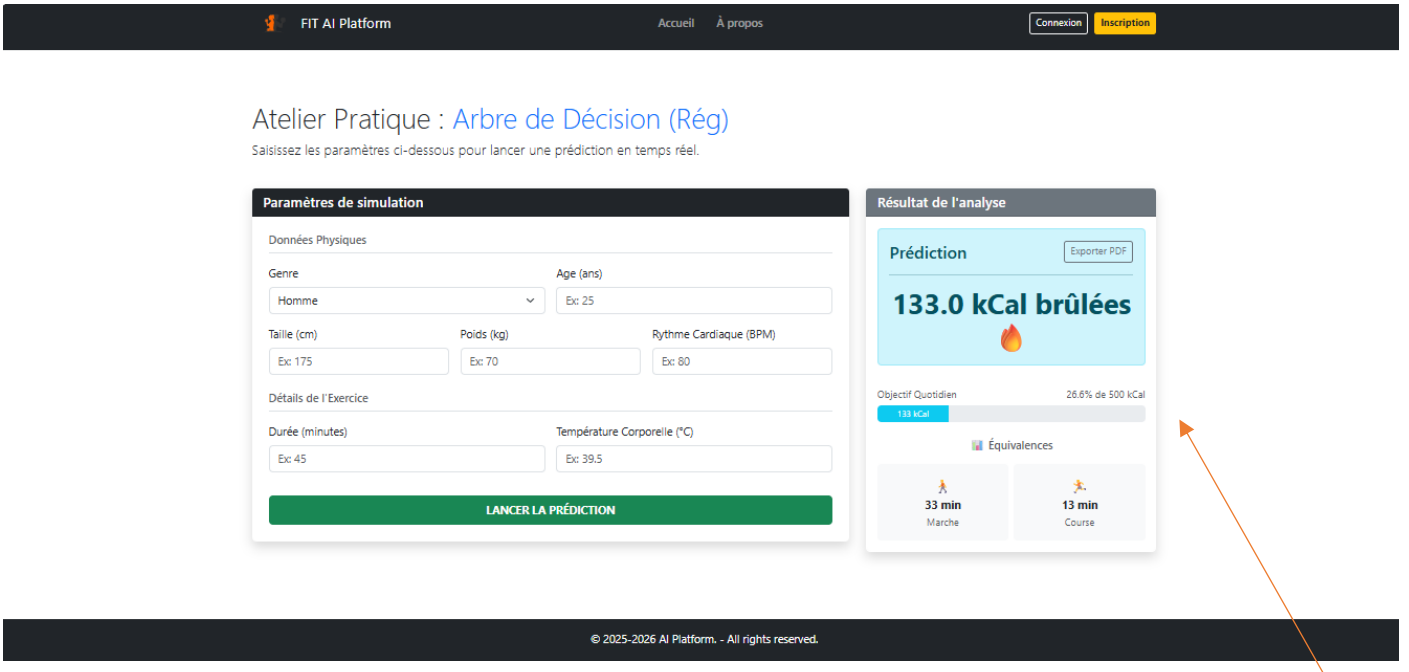

" Affichage du résultat de régression : prédiction de calories brûlées avec équivalences en activités physiques et progression vers l'objectif quotidien. Ici l'exemple d'arbre de décision . "

Pour Classification (prédire si Fit ou Non Fit) :

Avant le test :

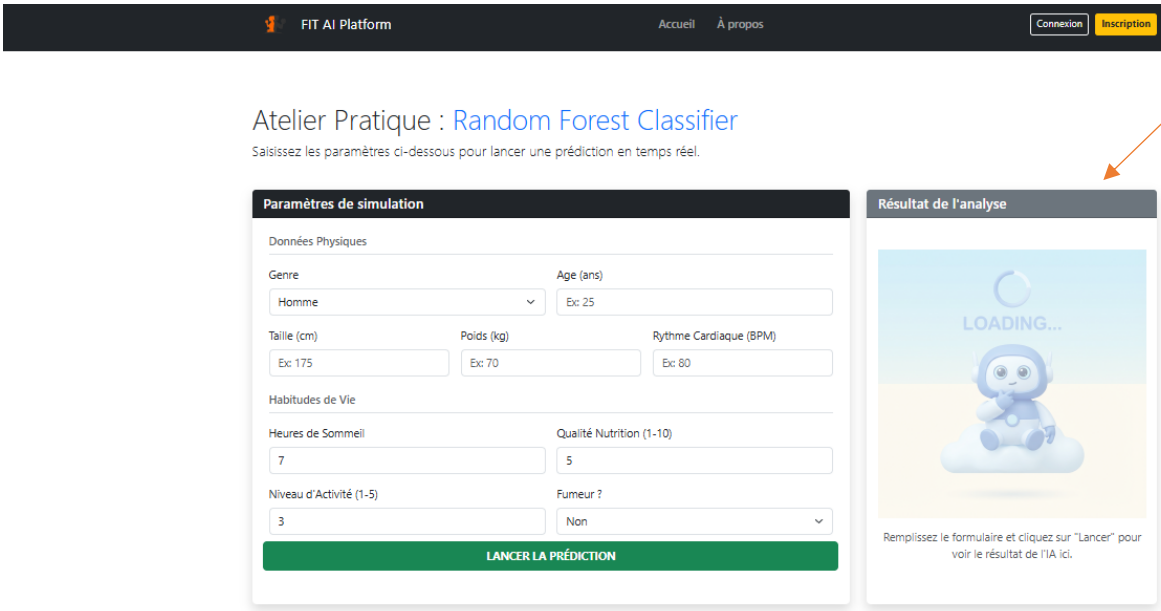

Après l'insertion du données :

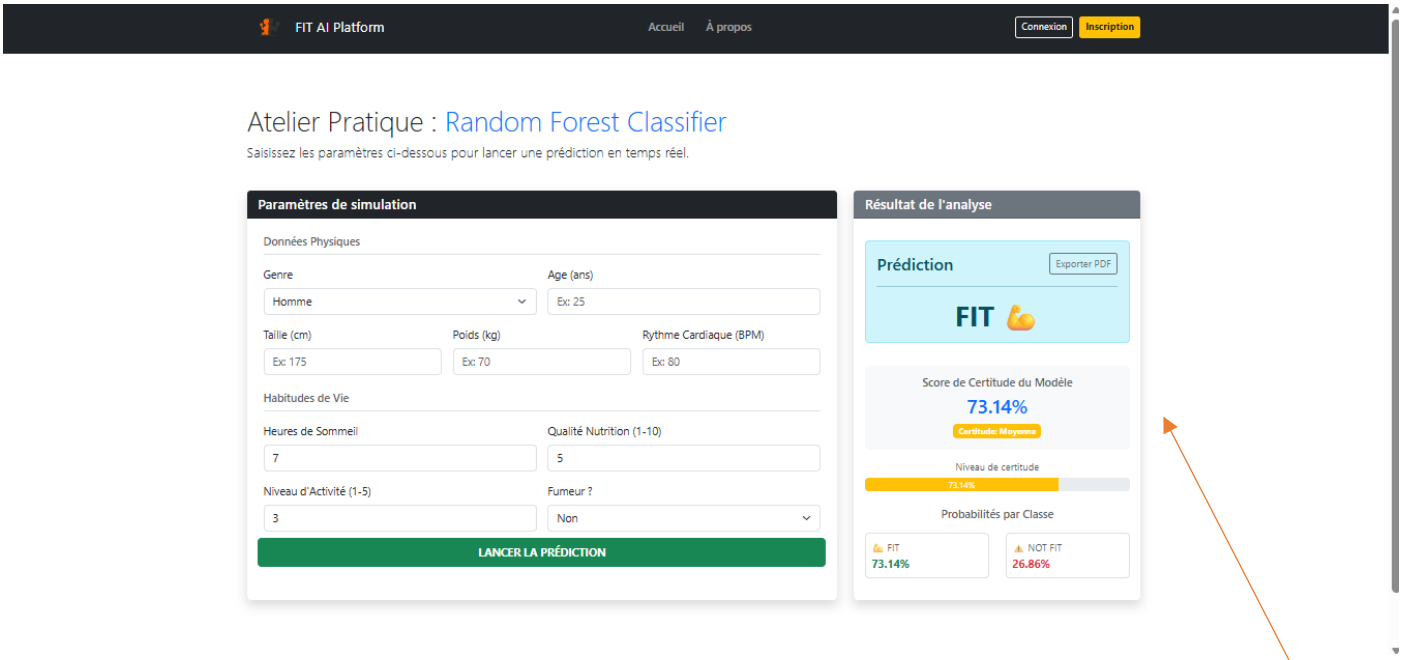

" Affichage du résultat de classification : prédiction "FIT" avec score de certitude de 73,14% et distribution des probabilités entre les deux classes possibles. Per exemple pour random forest . "

6. Les modèles de Machine Learning :

a. Traitement des datasets :

Pour la dataset de classification :

```
[5]: df = pd.read_csv('fitness_dataset.csv')
     df.isnull().sum()
```

```
[5]: age                 0
     height_cm           0
     weight_kg           0
     heart_rate          0
     blood_pressure      0
     sleep_hours       160
     nutrition_quality   0
     activity_index      0
     smokes              0
     gender              0
     is_fit              0
     dtype: int64
```

```
[6]: df['sleep_hours'] = df['sleep_hours'].fillna(df['sleep_hours'].median())
```

```
[7]: df.isnull().sum()
```

```
[7]: age                 0
     height_cm           0
     weight_kg           0
     heart_rate          0
     blood_pressure      0
     sleep_hours         0
     nutrition_quality   0
     activity_index      0
     smokes              0
     gender              0
     is_fit              0
     dtype: int64
```

```
# Nettoyage de la colonne 'smokes'
# On force tout en chaine de caracteres pour uniformiser puis on remplace
df['smokes'] = df['smokes'].astype(str)

#dictionnaire de remplacement
#car lorsqu'on fait directement l'encodage avec labelEncoder il donne 4 valeurs 0/1/2/3
map_smokes = {
    'yes': 1,
    'no': 0,
    '1': 1,
    '0': 0
}

# On applique le mapping
df['smokes'] = df['smokes'].map(map_smokes)

#Encodage de 'gender'
le = LabelEncoder()
df['gender'] = le.fit_transform(df['gender'])
```

Pour la dataset de Régression :

[2]:
```
df = pd.read_csv('calories_pred.csv')
```

[3]:
```
X = df.drop(columns=['Calories', 'Unnamed: 0', 'User_ID'])
y = df['Calories']


le = LabelEncoder()
X['Gender'] = le.fit_transform(X['Gender'])

scaler = StandardScaler()

num_cols = ['Age', 'Height', 'Weight', 'Duration', 'Heart_Rate', 'Body_Temp']

X[num_cols] = scaler.fit_transform(X[num_cols])
```

b. Les Modèles d' Apprentissage Supervisé

REGRESSIN LINIAIRE

[6]:
```
lr = LinearRegression()
lr.fit(X_train, y_train)

prd = lr.predict(X_test)
```

[7]:
```
mae = mean_absolute_error(y_test, prd)
mse = mean_squared_error(y_test, prd)
r2 = r2_score(y_test, prd)
print(mae)
print(mse)
print(r2)
```

```
8.44151355384971
131.99574575081698
0.9672937151257295
```

[8]:
```
import joblib
joblib.dump(lr, 'linear_reg.pkl')
```

[8]:
```
['linear_reg.pkl']
```

REGRESSION LOGISTIQUE

[14]:
```
logi_reg = LogisticRegression()
logi_reg.fit(X_train, y_train)


pred = logi_reg.predict(X_test)
print(f"Accuracy: {accuracy_score(y_test, pred)*100:.4f}%")
print(f"precision: {precision_score(y_test, pred)*100:.4f}%")
print(f"f1_score: {f1_score(y_test, pred)*100:.4f}%")
print(f"recall: {recall_score(y_test, pred)*100:.4f}%")
```

```
Accuracy: 76.2500%
precision: 74.3056%
f1_score: 69.2557%
recall: 64.8485%
```

[17]:
```
package = { "model": logi_reg, "scaler": scaler}
import joblib
joblib.dump(package, 'logistic_reg.pkl')
```

[17]:
```
['logistic_reg.pkl']
```

DECISION TREE CLASSIFICATION

[10]:
```
#modele
clf = DecisionTreeClassifier(criterion = 'entropy', max_depth=5, min_samples_leaf=4, min_samples_split=2,random_state=42)
clf.fit(X_train, y_train)

#evaluation
pred = clf.predict(X_test)
print(f"Accuracy: {accuracy_score(y_test, pred)*100:.4f}%")
print(f"precision: {precision_score(y_test, pred)*100:.4f}%")
print(f"f1_score: {f1_score(y_test, pred)*100:.4f}%")
print(f"recall: {recall_score(y_test, pred)*100:.4f}%")
```

```
Accuracy: 73.2500%
precision: 71.6418%
f1_score: 64.2140%
recall: 58.1818%
```

[11]:
```
import joblib
joblib.dump(clf, 'decision_tree_classification.pkl')
```

[11]:
```
['decision_tree_classification.pkl']
```

DECISION TREE REGRESSION ¶

[7]:
```
dt = DecisionTreeRegressor()
dt.fit(X_train, y_train)
pred = dt.predict(X_test)
```

[8]:
```
mae = mean_absolute_error(y_test, pred)
mse = mean_squared_error(y_test, pred)
r2 = r2_score(y_test, pred)
```

[9]:
```
print(mae)
print(mse)
print(r2)
```

```
3.3966666666666665
27.842666666666666
0.9931010641102141
```

[10]:
```
import joblib
joblib.dump(dt, 'decision_tree_regression.pkl')
```

[10]:
```
['decision_tree_regression.pkl']
```

RANDOM FOREST CLASSIFICATION

[12]:
```
model = RandomForestClassifier(n_estimators=100, max_depth=10, random_state=42)
model.fit(X, y)
```

[12]:
RandomForestClassifier

▶ Parameters

[13]:
```
y_pred = model.predict(X_test)
acc = accuracy_score(y_test, y_pred)
print(f"\nAccuracy: {acc*100:.4f}%")
print(f"precision: {precision_score(y_test, y_pred)*100:.4f}%")
print(f"f1_score: {f1_score(y_test, y_pred)*100:.4f}%")
print(f"recall: {recall_score(y_test, y_pred)*100:.4f}%")
```

```
Accuracy: 98.9130%
precision: 98.6395%
f1_score: 98.6395%
recall: 98.6395%
```

[14]:
```
package = {
    'modele': model,
    'encoders': {'gender': le_gender, 'smokes': le_smokes},
    'colonnes_features': X.columns.tolist()
}

joblib.dump(package, 'rf_classification.pkl')
print("'rf_classification.pkl'")
```

```
'rf_classification.pkl'
```

Random Forest REGRESSION

[7]:
```
model = RandomForestRegressor(n_estimators=100, random_state=42)
model.fit(X_train, y_train)
predictions = model.predict(X_test)
```

[8]:
```
mae = mean_absolute_error(y_test, predictions)
r2 = r2_score(y_test, predictions)
mse = mean_squared_error(y_test, predictions)


print(f"R2 Score : {r2:.4f}")
print(f"MAE : {mae:.2f}")
print(f"MSE : {mse:2f}")
```

```
R2 Score : 0.9982
MAE : 1.72
MSE : 7.200539
```

[9]:
```
import joblib
joblib.dump(model, 'rf_regression.pkl')
```

[9]:
```
['rf_regression.pkl']
```

SVM CLASSIFICATION

[9]:
```
model = SVC( kernel='rbf',C=1.0, gamma='scale',probability=True,random_state=42)
model.fit(X_train_scaled, y_train)
print("Modele SVM Classification entraine !")
```

```
Modele SVM Classification entraine !
```

[10]:
```
y_pred = model.predict(X_test_scaled)
accuracy = accuracy_score(y_test, y_pred)
print(f"\nAccuracy: {accuracy * 100:.2f}%")
print(f"precision: {precision_score(y_test, y_pred)* 100:.4f}%")
print(f"f1_score: {f1_score(y_test, y_pred)* 100:.4f}%")
print(f"recall: {recall_score(y_test, y_pred)* 100:.4f}%")
```

```
Accuracy: 82.07%
precision: 80.4511%
f1_score: 76.4286%
recall: 72.7891%
```

[11]:
```
model_package = {'model': model,'scaler': scaler,'label_gender': le_gender,'label_smokes': le_smokes,'feature_columns': features}
joblib.dump(model_package, 'svm_class_model.pkl')
print("Sauvegarde terminee : svm_class_model.pkl")
```

```
Sauvegarde terminee : svm_class_model.pkl
```

SVM REGRESSION

[7]:
```
model = SVR(kernel='rbf',C=1.0,gamma='scale',epsilon=0.1)
model.fit(X_train_scaled, y_train)
```

[7]:

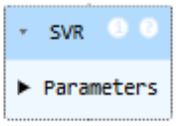

[8]:
```
y_pred = model.predict(X_test_scaled)

mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
print(f"R² Score : {r2:.4f}")
print(f"RMSE : {rmse:.2f}")
print(f"MAE : {mae:.2f} ")
print(f"MSE : {mse:.2f}")
```

```
R² Score : 0.9927
RMSE : 5.44
MAE : 2.37
MSE : 29.58
```

[9]:
```
model_package= {'model': model,'scaler': scaler,'label_encoders': label_reg,'features': features}
joblib.dump(model_package, 'svm_reg_model.pkl')
print("Sauvegarde : svm_reg_model.pkl")
```

```
Sauvegarde : svm_reg_model.pkl
```

XGBoost Classification

[8]:
```
model = XGBClassifier( random_state=42, n_estimators=100,max_depth=5,learning_rate=0.1,eval_metric="logloss")
model.fit(X_train_scaled, y_train)
print("Modele entraine avec succes !")
```

```
Modele entraine avec succes !
```

[9]:
```
y_pred = model.predict(X_test_scaled)
accuracy = accuracy_score(y_test, y_pred)
print(f"Accuracy : {accuracy * 100:.2f}%")
print(f"precision: {precision_score(y_test, y_pred)* 100:.4f}%")
print(f"f1_score: {f1_score(y_test, y_pred)* 100:.4f}%")
print(f"recall: {recall_score(y_test, y_pred)* 100:.4f}%")
```

```
Accuracy : 79.89%
precision: 77.0370%
f1_score: 73.7589%
recall: 70.7483%
```

[10]:
```
package = {'model': model,'scaler': scaler,'label_gender': le_gender,'label_smokes': le_smokes,'feature_columns': features}
joblib.dump(package, "xgboost_class_model.pkl")
print("Sauvegarde terminee : xgboost_class_model.pkl")
```

```
Sauvegarde terminee : xgboost_class_model.pkl
```

XGBOOST REGRESSION

[7]:
```
model = XGBRegressor(random_state=42,n_estimators=100,max_depth=5,learning_rate=0.1)
model.fit(X_train_scaled, y_train)
print("Modele entraine !")
```

```
Modele entraine !
```

[8]:
```
y_pred = model.predict(X_test_scaled)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"R² Score : {r2:.4f} ")
print(f"RMSE : {rmse:.2f}")
print(f"MAE : {mae:.2f}")
print(f"MSE : {mse:.2f}")
```

```
R² Score : 0.9989
RMSE : 2.07
MAE : 1.47
MSE : 4.28
```

[9]:
```
model_package = {'model': model,'scaler': scaler,'label_encoders': label_reg,'feature_columns': features}
joblib.dump(model_package, 'xgboost_reg_model.pkl')
print("Sauvegarde du modele : xgboost_reg_model.pkl")
```

```
Sauvegarde du modele : xgboost_reg_model.pkl
```

Conclusion :

Ce projet nous a permis de créer une plateforme de Machine Learning fonctionnelle, facile à utiliser et capable de traiter différents jeux de données. Grâce à ce travail, nous avons appris à préparer les données, entraîner des modèles, évaluer leurs performances et les intégrer dans une application web.